

# 基于 Hausdorff 度量的高光谱异常目标检测算法

赵春晖<sup>1</sup>, 尤伟<sup>1</sup>, 齐滨<sup>2</sup>, 王玉磊<sup>1</sup>

(1. 哈尔滨工程大学 信息与通信工程学院 黑龙江 哈尔滨 150001; 2. 哈尔滨工程大学 水声工程学院 黑龙江 哈尔滨 150001)

**摘 要:** 高光谱遥感异常目标检测中, 目标和背景光谱信息难以精确地界定, 导致目标检测性能下降。针对经典 RX 检测算法存在虚警概率高、计算量大、过程繁琐等缺点, 将 Hausdorff 度量引入高光谱异常检测, 利用改进的 Hausdorff 距离 (MHD) 从光谱匹配程度的角度, 进行了高光谱异常目标检测, 最大程度地将异常目标和背景分离。采用模拟数据和真实高光谱数据进行大量实验, 检测性能大幅提升, 算法的计算效率提高了 60%, 证明了本文算法比 RX 算法、因果 RX 算法和 KRX 算法检测效果好, 效率高等优势, 算法的低复杂度特性为硬件实现提供了良好的算法支持。

**关键词:** 高光谱遥感; 异常检测; RX 算法; 光谱匹配; Hausdorff 度量

**DOI:** 10.11990/jheu.201506087

**网络出版地址:** <http://www.cnki.net/kcms/detail/23.1390.u.20160527.1446.028.html>

**中图分类号:** TN911.73 **文献标志码:** A **文章编号:** 1006-7043(2016) 07-979-08

## Hyperspectral anomaly target detection algorithm based on Hausdorff measure

ZHAO Chunhui<sup>1</sup>, YOU Wei<sup>1</sup>, QI Bin<sup>2</sup>, WANG Yulei<sup>1</sup>

(1. College of Information and Communication Engineering, Harbin Engineering University, Harbin 150001, China; 2. College of Underwater Acoustic Engineering, Harbin Engineering University, Harbin 150001, China)

**Abstract:** In anomaly target detection in hyperspectral imagery, it can be difficult to accurately distinguish between the spectral information of the targets and background, which leads to a decline in target detection performance. The results of the classic RX detection algorithm have a high false alarm probability, and the process is characterized by a large amount of calculation and complexity. To address these issues, we introduce the Hausdorff metric to hyperspectral anomaly target detection, prove the usefulness of its application, and make a number of improvements to suppress noise interference. In terms of the spectral matching, we separate the targets and background to a greater degree based on the improved Hausdorff distance. Experiments were performed using both synthetic and real hyperspectral data. Moreover, the results show improved detection performance and an increase in computational efficiency of nearly 60%. These experimental results prove that this algorithm has lower computational complexity and better performance than the traditional RX algorithm, casual RX algorithm, and KRX algorithm and can better support the implementation of hardware.

**Keywords:** hyperspectral remote sensing; anomaly target detection; RX algorithm; spectral matching; Hausdorff metric

近年来, 高光谱遥感在目标探测与识别等方面具有了广泛的应用。在目标检测中, 不需要先验光谱信息的异常目标检测技术具有较强的实用性, 经典的异常检测算法是源于多光谱遥感的 RX 算法<sup>[1-2]</sup>。RX 算法最早是由 Reed 和 Xiaoli Yu 于 1990

年提出的, 是用于在高斯背景统计特性和空间白化的条件下目标光谱信息和背景光谱信息均未知的目标检测<sup>[3]</sup>。随后 Chang 等在 RX 算法基础上对检测算子进行了改进<sup>[4]</sup>, 2013 年, Acito 等提出了一种 RX 局部异常检测算子 (L-RXD), 提高了检测性能, Riley 等联合了欧氏距离构造了新检测器<sup>[2]</sup>, 有效地抑制了噪声的干扰。由于 RX 算法具有较大的计算量, 导致了算法计算效率不高<sup>[5]</sup>。随后, Chang 等在 RX 算法的基础上进行了进一步改进<sup>[6-8]</sup>, 提出了高光谱目标因果 RX 算子 (CRRXD) 和实时检测 RX 算法, 利用迭代思想大大加快了计算速度, 提高了算法

收稿日期: 2015-06-26.

网络出版日期: 2016-05-27.

基金项目: 国家自然科学基金项目 (61571145, 61405041); 黑龙江省自然科学基金项目 (ZD201216); 哈尔滨市优秀学科带头人基金项目 (RC2013XK009003); 中国博士后基金项目 (2014M551221); 中央高校基础研究基金项目 (HEUCF1608).

作者简介: 赵春晖 (1965-), 男, 教授, 博士生导师, 博士。

通信作者: 赵春晖, E-mail: zhaochunhui@hrbeu.edu.cn.

效率,但尚未从算法本身提高检测精度。为降低虚警概率, Kwon 等提出了一种基于核机器学习的非线性 RX 改进算法(KRX)<sup>[9]</sup>,该算法充分地利用了高光波段之间的非线性统计特性,然而,大量非线性核函数的运算使得算法效率降低。

在模式识别中,豪斯多夫(Hausdorff)度量被广泛应用于人脸检测和图像配准<sup>[10-12]</sup>,例如,何力提出一种基于 Hausdorff 距离的运动目标跟踪算法<sup>[13]</sup>,在运动物体的检测、识别和跟踪取得了较好的效果,H. Peyvandi 提出了将基于 Hausdorff 相似度的径向基函数神经网络应用于声呐信号的探测和分类<sup>[14]</sup>,在较低信噪比情况下获得了很好的检测效果,Manuel Grana 等提出了基于 Hausdorff 距离的高光谱数据特征检索算法<sup>[15]</sup>,提高了传统算法的效率和准确率。

针对现有 RX 异常检测算法虚警概率高、计算量较大的问题,本文提出了一种基于 Hausdorff 度量的高光谱异常目标检测算法。异常目标检测问题是一个当前像元与背景光谱信息匹配相似度问题,由于使用了 Hausdorff 距离作为距离测度无需考虑两个点集中元素之间的对应关系,可以有效地降低噪声的干扰,最大程度地将异常目标和背景分离,提高目标边缘检测概率,检测性能大幅提升,同时,计算复杂度大大降低,提高了计算效率。

## 1 异常目标检测 RX 算子

### 1.1 RX 异常检测算子

设有  $L$  个波段的高光谱像元的光谱向量可表示为一个  $L$  维列向量  $\mathbf{r}_i = [r_{1i} \ r_{2i} \ \dots \ r_{Li}]^T$ ,假设已知光谱信号为  $\mathbf{s} = [s_1 \ s_2 \ \dots \ s_L]^T$ ,令  $\mathbf{a} = [a_1 \ a_2 \ \dots \ a_L]^T$  为信号丰度,则二元假设检验可表示如下

$$\begin{cases} H_0: \mathbf{r} = \mathbf{n} \\ H_1: \mathbf{r} = \mathbf{a}\mathbf{s} + \mathbf{n} \end{cases} \quad (1)$$

式中:  $H_0$  代表目标不存在,  $H_1$  代表目标存在;  $\mathbf{n}$  是背景杂波信号,这里采用加性模型。通过广义似然比检验并经过一系列化简可以得出 RX 检测器,给出 RX 简化形式如下

$$\delta_{\text{RXD}} = (\mathbf{r} - \boldsymbol{\mu})^T \mathbf{K}^{-1}(\mathbf{r} - \boldsymbol{\mu}) \begin{cases} \geq \eta, & H_1 \\ < \eta, & H_0 \end{cases} \quad (2)$$

其中

$$\mathbf{K} = \frac{1}{N} \sum_{i=1}^N (\mathbf{r}_i - \boldsymbol{\mu})(\mathbf{r}_i - \boldsymbol{\mu})^T \quad (3)$$

式中:  $\mathbf{r}$  为  $L$  维待检测像元的光谱向量,  $\boldsymbol{\mu}$  为高光谱数据样本均值向量,  $\mathbf{K}$  为高光谱数据样本协方差矩阵,  $\eta$  为检测阈值,  $N$  为高光谱数据中观测样本的总数。

基于相关矩阵的因果 RX 异常检测算子:

$$\delta_{\text{CRRXD}} = \mathbf{r}_n^T \mathbf{R}^{-1}(n) \mathbf{r}_n \begin{cases} \geq \eta, & H_1 \\ < \eta, & H_0 \end{cases} \quad (4)$$

其中

$$\mathbf{R}(n) = \frac{1}{n} \sum_{i=1}^n \mathbf{r}_i \mathbf{r}_i^T \quad (5)$$

式中:  $\mathbf{r}_n$  是当前待检测像元 ( $n^{\text{th}}$ ) 的光谱特性,  $\mathbf{R}(n)$  是采样数据的相关矩阵,该相关矩阵由当前像元之前的所有像元光谱求相关性而得,具有因果特性,因此称之为因果 RX 算子(CRRXD)。

### 1.2 KRX 异常检测算子

核 RX (Kernel RX) 是 Kwon 等人针对 RX 算子存在的问题提出的改进算法,采用非线性函数  $\Phi$  将原始的高光谱遥感数据映射到高维特征空间中,得到特征空间中 KRX 算法可表示为

$$\text{KRX}(\Phi(\mathbf{r})) = (\Phi(\mathbf{r}) - \hat{\boldsymbol{\mu}}_{B\Phi})^T \hat{\mathbf{C}}_{B\Phi}^{-1}(\Phi(\mathbf{r}) - \hat{\boldsymbol{\mu}}_{B\Phi}) \quad (6)$$

其中

$$\hat{\mathbf{C}}_{B\Phi} = \sum_{i=1}^N (\Phi(\mathbf{r}_i) - \hat{\boldsymbol{\mu}}_{B\Phi})(\Phi(\mathbf{r}_i) - \hat{\boldsymbol{\mu}}_{B\Phi})^T / N \quad (7)$$

$$\hat{\boldsymbol{\mu}}_{B\Phi} = \sum_{i=1}^N \Phi(\mathbf{r}_i) / N \quad (8)$$

式中:  $\hat{\mathbf{C}}_{B\Phi}$  和  $\hat{\boldsymbol{\mu}}_{B\Phi}$  为特征空间背景的协方差矩阵和均值向量的估计值。 $\hat{\mathbf{C}}_{B\Phi}$  为对称阵,利用特征值分解可表示为  $\hat{\mathbf{C}}_{B\Phi} = \mathbf{V}_{\Phi} \boldsymbol{\Lambda}_{\Phi} \mathbf{V}_{\Phi}^T$ 。式(6)通过特征值分解,再将特征空间的点积使用“核技巧”转化为输入空间的核函数,即

$$k(\mathbf{x}, \mathbf{y}) = \langle \Phi(\mathbf{x}), \Phi(\mathbf{y}) \rangle = \Phi(\mathbf{x}) \cdot \Phi(\mathbf{y}) \quad (9)$$

化简最终得到 KRX 算子的最终算子表达式:

$$\text{KBX}(\Phi(\mathbf{r})) = (\Phi(\mathbf{r}) - \hat{\boldsymbol{\mu}}_{b\Phi})^T \hat{\mathbf{K}}_B^{-1}(\Phi(\mathbf{r}) - \hat{\boldsymbol{\mu}}_{b\Phi}) \begin{matrix} > \eta \\ < \eta \end{matrix} \quad (10)$$

其中:  $\mathbf{K}_B = \mathbf{K}(\mathbf{P}_B, \mathbf{P}_B)$  表示一个中心化的 Gram 矩阵,通过非中心化的 Gram 矩阵得到,  $\hat{\boldsymbol{\mu}}_{B\Phi}$  是估计均值,  $\mathbf{K}_B = \mathbf{K}(\mathbf{P}_B, \mathbf{P}_B)$  为定义  $N \times N$  中心化 Gram 核矩阵。

## 2 基于 Hausdorff 距离的异常检测算子

HD (Hausdorff distance) 为在度量空间中任意两个集合之间定义的一种距离,可以用来描述两组点集之间的相似程度。

设两个点集:  $A = \{a_1 \ a_2 \ a_3 \ \dots \ a_m\}$ ,  $B = \{b_1 \ b_2 \ b_3 \ \dots \ b_n\}$

定义 Hausdorff 距离为

$$\text{HD}(A, B) = \max\{h(A, B) \ h(B, A)\} \quad (11)$$

式中:  $h(A, B)$  和  $h(B, A)$  为两个点集  $A$  和  $B$  的单

向距离, 分别定义为

$$h(A, B) = \max_{a \in A} \min_{b \in B} \|a - b\| \quad (12)$$

$$h(B, A) = \max_{b \in B} \min_{a \in A} \|b - a\| \quad (13)$$

式(11)也被称为双向 HD 距离, 是最简单的形式,  $\|\cdot\|$  表示某种距离范数, 如欧氏距离。两个单向 HD 距离, 通常是不一样的, 表示了其中一个集合中最不匹配的点到最近的另一个集合中的点的距离。应用 HD 距离需要证明其在集合族内部是完备度量。

定理: 用  $\kappa$  表示  $\mathbf{R}^n$  中全体非空紧致子集构成的集合族, 即  $\text{HD}: \kappa \times \kappa \rightarrow \mathbf{R}$ ,  $\text{HD}(A, B) = \max\{h(A, B), h(B, A)\}$ , HD 是  $\kappa$  上一个完备度量, 称作 Hausdorff 度量。

证明: 根据度量的定义, 度量需要满足三个条件, 即非负性, 对称性和三角不等式。非负性和对称性显然, 下面证明三角不等式。设  $A, B, C \in \kappa$  根据紧致性, 显然有  $\text{HD}(A, B) < \infty$ 。设  $\varepsilon > 0$ , 那么存在  $b \in B$  使得

$$h(a, b) < \text{HD}(A, B) + \varepsilon \quad (14)$$

因此, 存在  $z \in C$  使得

$$h(b, z) < \text{HD}(B, C) + \varepsilon \quad (15)$$

这证明  $A$  包含在  $C$  的  $h(A, B) + h(B, A) + 2\varepsilon$  邻域的闭包内。类似地,  $C$  包含在  $A$  的  $h(A, B) + h(B, C) + 2\varepsilon$  邻域的闭包内。所以

$$\text{HD}(A, C) \leq \text{HD}(A, B) + \text{HD}(B, C) + 2\varepsilon \quad (16)$$

由于  $\varepsilon > 0$  的任意性, 证得三角不等式性质

$$\text{MHD}(A, B) = \max\{\text{mh}(A, B), \text{mh}(B, A)\} \quad (17)$$

HD 距离作为一种度量, 等于两个单向 HD 距离的最大值, 它可以解释为保证两个集合互相包含所需要的最小半径, 两个集合越不相似, 其互相包含的半径越大, 因此, 它衡量了两个点集的最大不相似程度, 可以广泛应用于图像配准、目标识别和检测。

在 HD 距离原始定义中, 它对噪声干扰的集合轮廓非常敏感, 要使得两组点集之间的 HD 距离小, 就要保证一个集合的每一个元素都需要位于另一个集合的附近。假设一个集合中存在一个或被噪声干扰的点不满足这个条件, 则这两个集合的 HD 距离将完全取决于噪声点的位置, 适应性大大降低。为提高其鲁棒性, 采用改进的 HD 距离, 表示为

$$\text{MHD}(A, B) = \max\{\text{mh}(A, B), \text{mh}(B, A)\} \quad (18)$$

其中:

$$\text{mh}(A, B) = \frac{1}{N_A} \sum_{a \in A} \min_{b \in B} \|a - b\| \quad (19)$$

$N_A = m$  是  $A$  点集中元素的数量, 改进的  $\text{mh}(A, B)$  表示为  $B$  集合中元素最小值与  $A$  中所有元素非对应欧氏距离的均值。改进的 HD 距离称为 MHD 距离, MHD 距离可以有效地缓解  $A$  中噪声对距离测度的敏感程度。

RX 检测算子本质是利用马氏距离进行待检测像元和背景相似度检测, 引入 Hausdorff 距离度量解决了 RX 检测的灰度值图像高虚警问题, 对比于 KRX 算法, 本方法从根本上降低了计算复杂度, 使得计算效率大大提高。

Hausdorff 距离用于衡量两组点集之间的相似程度, 在异常目标检测任务中, 提取像元光谱维数据。Kwon 提出了一种基于双层窗特征分解的异常检测算法。该算法利用外窗和内窗两个窗口, 最大化分离背景向量和目标向量的光谱特征。其具体局部检测模型如图 1 所示。外层窗截取检测背景信息, 而检测点位于内窗中央, 内窗的其他部分认为是目标不做操作。




图 1 高光谱异常目标局部检测模型

Fig.1 Hyperspectral anomaly target local detection model

由于空间上同一个位置附近的背景光谱曲线差异不大, 对经过双窗模型得到的背景光谱数据取均值作为平均背景光谱向量  $B$ , 同时, 内窗提取的像元作为待检测像元光谱向量  $A$ , 对两个向量求改进的 HD 距离作为待检测像元的检测结果。用 MHD 距离来度量两个向量的相似度, 两个向量的数据越相似, 其 MHD 距离越小, 两个向量的数据差别越大, 其 MHD 距离越大, 检测结果就越大, 超过阈值显示检测到异常。另外, 对背景光谱数据取均值作为平均背景光谱向量可以弱化 MHD 距离对  $B$  中噪声的敏感程度。因此, 此方法可以提升原始 HD 距离对  $A$  和  $B$  的抗噪声性能。实际上, 在高光谱异常目标检测中, 相邻像元光谱数据具有相似分布特性, 从原理上, 应用 MHD 距离可以充分抑制噪声对检测结果的干扰, 对两个向量进行匹配是可以对各个元素的微小差异进行积累, 它会更好的检测相似度,

因此,可以获得更好的检测结果。

基于 MHD 距离的高光谱异常检测的计算过程:

1) 对于高光谱数据进行预处理,求均值做归一化。

2) 设待检测像元  $x_i$ , 高光谱数据波段数  $L$ , 利用双窗模型在排除目标像元的前提下最大化提取待检测像元附近背景  $W = \{x_i(j)\} \quad j = 1, 2, \dots, N \quad j = 1, 2, \dots, M \quad N$  是待检测像元总数,  $M$  是待检测像元背景像元个数。

3) 将提取到的背景像元取均值作为匹配背景, 即  $x_{im} = \frac{\sum x_i(j)}{M}$ 。

4) 分别计算待检测像元到匹配背景像元和匹配背景像元到待检测像元的 MHD 距离:

$$mh(x_i, x_{im}) = \frac{1}{L} \sum_{a \in x_i} \min_{b \in x_{im}} \|a - b\|$$

$$mh(x_{im}, x_i) = \frac{1}{L} \sum_{a \in x_{im}} \min_{b \in x_i} \|a - b\|$$

5) 比较  $mh(x_i, x_{im})$  和  $mh(x_{im}, x_i)$  取其中的最大值作为 MHD 距离, 将 MHD 距离做阈值判决输出结果。

### 3 实验与结果分析

为验证本文提出的 MHD 算法的有效性和高效性, 分别用合成的模拟数据和真实的高光谱数据进行了实验。计算机的硬件配置, 处理器型号为 Intel Core i5, 主频 2.5 GHz, 内存为 DDR3 8 GB, 仿真实验平台为 MATLAB2014 版本。

#### 3.1 高光谱数据描述

##### 3.1.1 模拟数据介绍

基于本文 MHD 算法针对异常目标检测, 取用真实数据 AVIRIS 高光谱遥感中多种异常目标进行目标插入, 该 AVIRIS 高光谱数据有 126 个波段, 数据共有  $400 \times 400$  像元。图 2 中圈出了四种地物的地理分布, 该四种地物分别是油桶 (gasoline can, G)、房屋 (house, H)、树木 (tree, T) 和飞机 (plane, P)。合成  $90 \times 90$  空间大小的含有 126 个波段的高光谱数据进行仿真实验。

该模拟数据共有  $4 \times 4 = 16$  个异常点。该 16 个  $3 \times 3$  大小的像元生成如下: 用图 2 的四种物质 (G, H, T, P) 的光谱特性模拟四种异常目标, 每行异常目标由同种物质构成。其中第一列由纯像元构成, 第二列包含了 75% 异常像元光谱特性和 25% 背景光谱特性, 第三列包含了 50% 异常像元光谱特性和 50% 背景光谱特性, 第四列包含了 25% 异常像元光谱特性和 75% 背景光谱特性。该图可用于不同背

景干扰下的多种异常目标探测。图 3 即为模拟数据与目标分布。





图 2 四类异常目标在真实数据中的分布

Fig.2 The distribution of four types of anomaly targets in real data



(a) 第100波段


(b) 目标分布

图 3 模拟数据第 100 波段和目标分布

Fig.3 Synthetic data 100 band image and the target distribution

##### 3.1.2 真实数据

为了验证本文提出的算法在实际应用中的有效性, 采用一幅真实的高光谱数据进行仿真实验。该数据是美国圣地亚哥海军基地 AVIRIS 高光谱数据截取的  $100 \times 100$  空间大小的数据。该数据有 224 个波段, 去除水的吸收带和信噪比较低的波段后, 余下的 126 个波段用于实验, 图 4 即为原始高光谱的第 100 波段灰度显示和真实地物分布。



(a) 第100波段灰度图

(b) 真实地物分布

图 4 真实数据第 100 波段灰度图和真实地物分布

Fig.4 Real data 100 band image and the target distribution

##### 3.2 模拟数据仿真实验及分析

利用模拟数据的目的在于测试 6 种算法对于不

同背景干扰下的多种异常目标的抗噪声性能。实验中,局部算子选择目标检测窗口设为  $3 \times 3$  像元,背景信息提取窗口大小设为  $11 \times 11$  像元。首先对原始高光谱数据归一化,然后根据合成数据大小和目标分布,对图 2 所示的合成数据分别进行全局 RX 算法( G-RXD)、局部 RX 算法( L-RXD)、全局因果

RX 算法( G-CRRXD)、局部因果 RX 算法( L-RXD)、KRX 算法和本文提出的 MHD 算法进行检测。KRX 算法中的核函数采用的是高斯径向基( RBF) 核函数  $k(x \cdot x_i) = \exp(-\|x - x_i\|^2/\delta^2)$ ,将原始数据映射到高维特征空间,通过多次仿真实验比较最终确定径向基函数的宽度  $\delta^2 = 100$ 。




图 5 检测结果二值图像对比  
Fig.5 Results of binary image contrast

对比最终检测结果的二值图像,如图 5 所示。图 5( a) ~ ( d) 描述了采用 RX 检测算子在设定的阈值下得到的异常检测结果,基于马氏距离的全局 RX 算法检测效果很不理想,全局检测算子存在漏检目标的情况严重,图 5( c)、( d) 是局部算子,但由于选择的外窗的背景信息并不是完全服从正态分布,因此在 16 个异常目标中每一个都有不同程度的漏警,且在异常目标周围受背景干扰产生很多虚警点。图 5( e)、( f) 可以看出, KRX 算法较 RX 算法检测效果好很多,没有产生漏警,只是在个别目标周围产生了虚警点,相比较而言, MHD 算法效果更好,几乎没有产生漏警和虚警点,对多种异常目标的检测具有通用性。

为了量化分析本文算法的优越性,以不同算子检测的结果中的目标所占像元数量、虚警所占像元数量和计算时间作为性能指标,对上述算法进行比较分析,如表 1 所示。

如表 1 所示,由于 MHD 算法的计算复杂度较 RX 算法小很多,因此计算效率大大提高, KRX 算法取得了较好的检测效果但计算时间也有所增加,而 MHD 算法进一步减少了计算,极大地减少了计算时间。基本达到了实时处理的要求,因此该算法更具实用性。

表 1 不同算法性能量化分析

Table 1 The quantitative analysis of different algorithms

检测算法	目标像元	虚警像元	t/s
G-RXD	60	38	28.517
L-RXD	114	30	8.564 0
G-CRRXD	73	36	27.325
L-CRRXD	119	33	8.175 0
KRX	144	31	51.381
MHD	<b>144</b>	<b>0</b>	<b>4.029 0</b>

3.3 真实数据实验结果与分析

实验中,对高光谱数据去均值做归一化后,采用与模拟数据实验相同的局部窗口和核函数。为了更直观地表现 HD 距离用于检测的优越性,实验对比两种算法绘制出了检测灰度图像的 3D 峰度对比图如图 6 所示。其中 XY 轴二维平面上的点代表像元在灰度图中位置,图中蓝色到红色对应的为灰度依次由小到大,三维 Z 轴纵坐标表示对应像元灰度值的强弱(即峰度),由图中的峰度对比得出结论,和 KRX 算法相比,采用本文的 MHD 算法的检测结果能够产生较低的漏警概率,更容易的选择最佳阈值进行目标和背景的分离。

图 6 较直观地表现了传统 RX、KRX 和 MHD 算法对圣地亚哥海军基地数据飞机场的检测结果,其中 RX 算法检测效果不理想,由于背景光谱信息的混扰在检测到的目标附近产生较多虚警目标,KRX 算法由于加入了非线性核函数,效果有所改善,但在少量目标附近仍不能区分目标和背景,采用的 MHD

算法是从光谱匹配程度的角度出发,检测目标和背景光谱信息差异,并将这种差异作为不相似度量,将不相似度超过阈值判断为目标,否则为判断为背景。

ROC 曲线又称为接收机工作特性曲线,是一种表述检测概率  $P_d$  与虚警概率  $P_f$  之间变化关系的曲线,是检测性能定量分析中常用的手段。

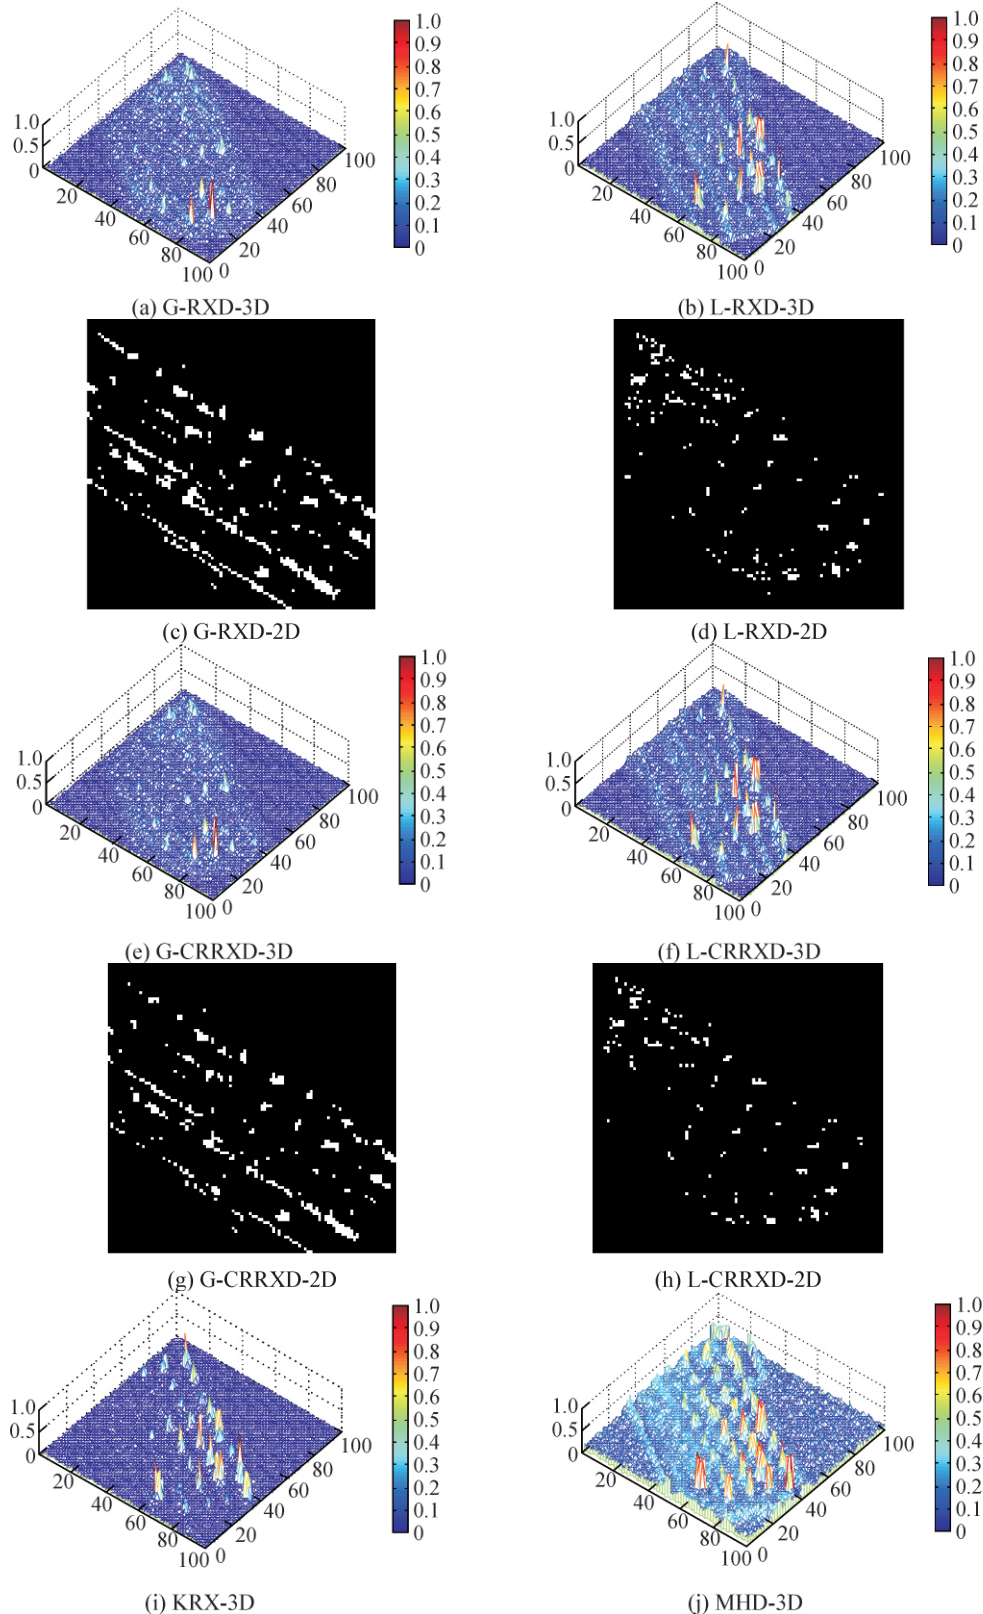




图 6 六种算法不同检测效果对比

Fig.6 Kurtosis of MHD compared with other method

图 7 给出了 RX、KRX 和 MHD 三种算法的 ROC 曲线,一般要求虚警概率不能大于 10%,从图中可以看出,在相同的虚警概率下,MHD 的检测概率要远远高于 RX 和 KRX 算法,从而可知 MHD 算法性能远远优于其他两种算法。

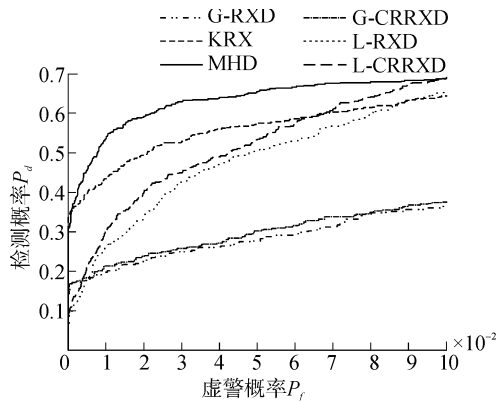


图 7 ROC 曲线对比

Fig.7 ROC curves contrast

与模拟数据实验相同,为了量化分析本文算法的优越性,与表 1 对比,增加了目标个数虚警个数作为性能指标对上述算法进行比较分析,如表 2 所示。

表 2 不同算法性能量化分析

Table 2 The quantitative analysis of different algorithms (Real data)

检测算法	目标数	目标像元	虚警像元	时间/s
G-RX	29	91	205	35.728 6
L-RX	30	93	103	10.506 1
G-CRRX	30	96	184	33.125 4
L-CRRX	29	116	86	10.753 0
KRX	30	137	22	63.642 9
MHD	31	142	6	4.7107 4

由表 2 可以看出,与其他检测算法相比,MHD 算法在提升检测性能的同时极大地减少了计算时间,这是因为,在 RX 和 KRX 中存在着矩阵求逆运算和复杂的矩阵操作导致耗时较长,而在 MHD 中

仅仅需要集合运算,这大大降低了计算复杂度,节省了计算时间,可以大量应用到具有较低计算能力的硬件实现中,例如 FPGA、ARM、DSP 等。上述实验充分证明了 MHD 算法的有效性、通用性和实用性。

#### 4 结论

针对现有高光谱异常检测的 RX 算法易受背景干扰检测性能不佳和计算复杂度高这一问题,本文将 Hausdorff 度量引入高光谱异常检测,利用改进的 Hausdorff 距离(MHD)从光谱匹配程度的角度,进行了高光谱异常目标检测,最大程度地将异常目标和背景分离,同时降低了算法的计算复杂度。实验结果表明:

- 1) 本文提出的 MHD 算法可以更好地检测异常目标和背景的光谱相似度,对不同复杂背景下的多异常目标具有很好的鲁棒性;
- 2) 算法时间显著降低,接近实时高光谱异常目标检测,较低的计算复杂度为硬件实现提供了良好的算法支持。

对于极弱小异常目标的检测还存在一些不足,下一步将针对异常窗口的选择提取背景光谱信息进行深入研究。

#### 参考文献:

[1] REED I S, YU X. Adaptive multiple-band CFAR detection of an optical pattern with unknown spectral distribution [J]. IEEE transactions on acoustics, speech, and signal processing, 1990, 38( 10): 1760-1770.

[2] RILEY R A, NEWSOM R K, ANDREWS A K. Anomaly detection in noisy hyperspectral imagery [C]//Proceedings of the SPIE 5546, Imaging Spectrometry X. United States: SPIE, 2004: 159-170.

[3] 王立国,赵春晖. 高光谱图像处理技术[M]. 北京: 国防工业出版社, 2013: 110-169.

WANG Liguang, ZHAO Chunhui. Processing techniques of hyperspectral imagery [M]. Beijing: National Defense Industry Press, 2013: 110-169.

(下转第 996 页)



- 贡献潜力[J]. 中国人口·资源与环境, 2015, 25(6): 89-97.
- HE Lihua, YANG Pan, MENG Yanlin, et al. Contribution potential of optimizing energy structure to low carbon Shandong [J]. China population, resources and environment, 2015, 25(6): 89-97.
- [12] APERGIS N, OZTURK L. Testing environmental Kuznets Curve hypothesis in Asian countries [J]. Ecological indicators, 2015, 52: 16-22.
- [13] MAGAZZINO C. Economic growth, CO<sub>2</sub> emissions and energy use in Israel [J]. International journal of sustainable development & world ecology, 2015, 22(1): 89-97.
- [14] 迟国泰, 齐菲, 张楠. 基于最优组合赋权的城市生态评价模型及应用[J]. 运筹与管理, 2012, 21(2): 183-191.
- CHI Guotai, QI Fei, ZHANG Nan. The city's ecosystem evaluation model based on optimal combination weights and its application [J]. Operations research and management science, 2012, 21(2): 183-191.
- [15] 邓聚龙. 灰理论基础[M]. 武汉: 华中科技大学出版社, 2002: 21-36.
- [16] 王韶华, 于维洋, 张伟, 等. 基于产业和能源的河北省分产业碳强度因素分析[J]. 经济地理, 2015, 35(5): 166-173.
- WANG Shaohua, YU Weiyang, ZHANG Wei, et al. The decomposition analysis for Hebei's industrial carbon intensity based on industry and energy [J]. Economic geography, 2015, 35(5): 166-173.
- [17] PAWLAK Z, GRZYMALA-BUSSE J, SLOWINSKI R, et al. Rough sets [J]. Communications of the ACM, 1995, 38(11): 88-95.
- [18] 陈启明, 陈华友. 改进的熵值法在确定组合预测权系数中的应用[J]. 统计与决策, 2011(13): 159-160.
- CHEN Qiming, CHEN Huayou. The implication of improved entropy method in determining the weight coefficient of combination forecasting [J]. Statistics and decision, 2011(13): 159-160.

### 本文引用格式:

许珊, 范德成, 王韶华. 区域产业结构与能源结构低碳关联评价[J]. 哈尔滨工程大学学报, 2016, 37(7): 990-996.

XU Shan, FAN Decheng, WANG Shaohua. Evaluation of low-carbon correlation between regional industrial structure and energy structure [J]. Journal of Harbin Engineering University, 2016, 37(7): 990-996.

### (上接第 985 页)

- [4] CHANG C I, CHIANG S S. Anomaly detection and classification for hyperspectral imagery [J]. IEEE transactions on geoscience and remote sensing, 2002, 40(6): 1314-1325.
- [5] MATTEOLI S, VERACINI T, DIANI M, et al. A locally adaptive background density estimator: an evolution for RX-based anomaly detectors [J]. IEEE geoscience and remote sensing letters, 2014, 11(1): 323-327.
- [6] ZHAO Chunhui, WANG Yulei, QI Bin, et al. Global and local real-time anomaly detectors for hyperspectral remote sensing imagery [J]. Remote sensing, 2015, 7(4): 3966-3985.
- [7] CHEN S Y, WANG Yulei, WU Chaocheng, et al. Real-time causal processing of anomaly detection for hyperspectral imagery [J]. IEEE transactions on aerospace and electronic systems, 2014, 50(2): 1511-1534.
- [8] WANG Yulei, CHEN S Y, LIU Chunhong, et al. Background suppression issues in anomaly detection for hyperspectral imagery [C]//Proceedings of the SPIE 9124, Satellite Data Compression, Communications, and Processing X. United States: SPIE, 2014.
- [9] GOLDBERG H, KWON H, NASRABADI N M. Kernel eigenspace separation transform for subspace anomaly detection in hyperspectral imagery [J]. IEEE geoscience and remote sensing letters, 2007, 4(4): 581-585.
- [10] 王靖, 朱梦宇, 赵保军, 等. 基于小波和改进型 Hausdorff 距离的遥感图像配准方法 [J]. 电子学报, 2006, 34(12): 2167-2169.
- WANG Jing, ZHU Mengyu, ZHAO Baojun, et al. A remote sensing image registration method based on wavelet decomposition and the improved Hausdorff distance [J]. Acta electronica sinica, 2006, 34(12): 2167-2169.
- [11] 杨清夙, 游志胜, 张先玉. 基于豪斯多夫距离的快速多人脸检测算法 [J]. 电子科技大学学报, 2004, 33(4): 407-409.
- YANG Qingsu, YOU Zhisheng, ZHANG Xianyu. Fast multi-face detection algorithm based on Hausdorff distance [J]. Journal of university of electronic science and technology of China, 2004, 33(4): 407-409.
- [12] YI J H, BHANU B, LI Ming. Target indexing in SAR images using scattering centers and the Hausdorff distance [J]. Pattern recognition letters, 1996, 17(11): 1191-1198.
- [13] 何力. 一种基于 Hausdorff 距离的运动目标跟踪算法 [D]. 合肥: 中国科学技术大学, 2010.
- HE Li. An object tracking algorithm based on hausdorff distance [D]. Hefei: University of Science and Technology of China, 2010.
- [14] PEYVANDI H. Evolving radial basis function neural network with Hausdorff similarity measure for SONAR signals detection/classification [C]//Proceedings of the Oceans 2009-Europe. Bremen: IEEE, 2009.
- [15] GRANA M, VEGANZONES M A. An endmember-based distance for content based hyperspectral image retrieval [J]. Pattern recognition, 2012, 45(9): 3472-3489.

### 本文引用格式:

赵春晖, 尤伟, 齐滨, 等. 基于 Hausdorff 度量的高光谱异常目标检测算法 [J]. 哈尔滨工程大学学报, 2016, 37(7): 979-985.

ZHAO Chunhui, YOU Wei, QI Bin, et al. Hyperspectral anomaly target detection algorithm based on Hausdorff measure [J]. Journal of Harbin Engineering University, 2016, 37(7): 979-985.